

Análisis de Autocorrelación Espacial

Wladimir Aldo Carlosviza Amanqui

7 de octubre de 2025

Índice

1. Resumen de los Artículos y su Convergencia con la Autocorrelación Espacial	2
1.1. Resúmenes de los Artículos	2
1.1.1. Artículo 1: Exposición Costera al Aumento del Nivel del Mar	2
1.1.2. Artículo 2: Heterogeneidad Espacial de la Incidencia de Paperas en China	2
1.1.3. Artículo 3: Evolución de la Vegetación en las Montañas Yinshan	2
1.2. Convergencia de los Artículos	2
1.3. Definición de Autocorrelación Espacial	3
1.4. Aplicaciones en Cada Artículo	3
2. Implementación en R: Cálculo del Índice de Moran Global	4
2.1. Librerías Necesarias	4
2.2. Interpretación de las Librerías	4
2.3. Creación de Polígonos Espaciales Simulados	4
2.4. Interpretación	4
2.5. Asignación de Variable de Exposición	5
2.6. Interpretación	5
2.7. Construcción de Matriz de Pesos Espaciales	5
2.8. Salida del Comando	6
2.9. Interpretación de la Matriz de Pesos Espaciales	6
2.10. Cálculo del Índice de Moran Global	7
2.11. Salida del Comando	7
2.12. Interpretación del Índice de Moran Global	7
2.13. Visualización del Mapa de Exposición	8
2.14. Interpretación del Mapa	8
2.15. Comparación con los Artículos Analizados	10
2.16. Conclusiones del Análisis Espacial	10
3. Referencias Bibliográficas	11

1. Resumen de los Artículos y su Convergencia con la Autocorrección Espacial

1.1. Resúmenes de los Artículos

1.1.1. Artículo 1: Exposición Costera al Aumento del Nivel del Mar

Assessing coastal exposure to Sea Level Rise: a coupled approach of qualitative modeling and spatial autocorrelation analysis (Lamhadri et al., 2025).

Este estudio evalúa la vulnerabilidad costera ante el aumento del nivel del mar en la región atlántica de Marruecos, específicamente en la costa de Salé, mediante el modelo InVEST. Los resultados evidencian que la protección de hábitats naturales reduce significativamente el riesgo de exposición, mientras que su pérdida eleva la vulnerabilidad extrema (Lamhadri et al., 2025). Se destaca una mayor exposición en la zona sur debido a factores geográficos y ecológicos. El índice de exposición mostró una autocorrelación espacial notable (índice de Moran = 0.7), lo que indica agrupamiento de áreas con exposición similar (Lamhadri et al., 2025). El modelo analizó 267 puntos a lo largo de 25 km de costa con una resolución de 100 metros.

1.1.2. Artículo 2: Heterogeneidad Espacial de la Incidencia de Paperas en China

Spatial stratified heterogeneity of mumps incidence in China: a Geodetector-based analysis of driving factors (Hu et al., 2025).

Este trabajo analiza la distribución espacial de la incidencia de paperas en China usando Geodetector y autocorrelación espacial. Detecta una heterogeneidad marcada con agrupamientos alto-alto en el oeste y bajo-bajo en el este (Hu et al., 2025). La dependencia infantil emerge como principal factor, interactuando con indicadores económicos y educativos. El análisis reveló un índice de Moran global de 0.399 ($p < 0.001$), confirmando una fuerte dependencia espacial de la transmisión de paperas (Hu et al., 2025). El estudio abarcó 31 provincias chinas durante el año 2020 y propone estrategias preventivas diferenciadas por región.

1.1.3. Artículo 3: Evolución de la Vegetación en las Montañas Yinshan

A remote sensing evidence on the marginality, fragmentation and spatiotemporal heterogeneity of vegetation evolution characteristics in the Yinshan Mountains, China (Yan et al., 2025).

Examina la evolución de la vegetación mediante el índice NDVI (1984–2022), identificando patrones de variabilidad espacio-temporal (Yan et al., 2025). El índice de Moran bivariado ($I = 0.88$, $p < 0.01$) revela fuerte asociación entre vegetación y precipitación, confirmando la sensibilidad climática del ecosistema y la necesidad de restauración ambiental (Yan et al., 2025). El estudio demostró que la precipitación fue el factor climático dominante que influye en las variaciones del NDVI, mostrando una alta correlación positiva en el 80.05 % del área total.

1.2. Convergencia de los Artículos

Los tres estudios coinciden en el uso de la **autocorrección espacial** para identificar patrones de dependencia geográfica. Esta convergencia se manifiesta en:

- **Uso del índice de Moran** para medir similitud espacial y detectar agrupamientos o *hotspots* (Lamhadri et al., 2025; Hu et al., 2025; Yan et al., 2025).
- **Integración con métodos complementarios** como InVEST (Lamhadri et al., 2025), Geodetector (Hu et al., 2025) y análisis de tendencias (Yan et al., 2025), para explicar la heterogeneidad local.
- **Aplicaciones prácticas** orientadas a la sostenibilidad: gestión costera, control de brotes y restauración ecológica.

1.3. Definición de Autocorrelación Espacial

La **autocorrelación espacial** evalúa la similitud de valores de una variable entre ubicaciones geográficas cercanas, de acuerdo con la Primera Ley de Tobler: *"Todo está relacionado con todo, pero las cosas cercanas están más relacionadas que las distantes"*.

El índice de Moran global (rango -1 a 1) permite cuantificar este grado de asociación:

$$I = \frac{n}{\sum_i \sum_j w_{ij}} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2} \quad (1)$$

Donde:

- n = número de unidades espaciales
- x_i, x_j = valores de la variable en ubicaciones i y j
- \bar{x} = media de la variable
- w_{ij} = peso espacial entre ubicaciones i y j

Valores positivos indican *clustering* (agrupamiento espacial), valores negativos indican dispersión, y valores cercanos a cero sugieren aleatoriedad espacial. Su aplicación facilita la identificación de patrones no aleatorios en fenómenos ambientales y epidemiológicos, aportando una visión integral de la estructura espacial de los datos.

1.4. Aplicaciones en Cada Artículo

Artículo 1: La autocorrelación espacial (Moran $I = 0.7$) aplicada al índice de exposición del modelo InVEST evidencia agrupamientos costeros de alto riesgo, guiando estrategias de protección (Lamhadri et al., 2025). Los resultados mostraron que el índice de Moran permaneció consistente en todos los escenarios analizados, destacando patrones de dependencia espacial estables. El análisis reveló que con protección de hábitat, la exposición costera se mantiene entre baja y moderada (51.3 %), mientras que sin protección, el 56.9 % de la costa enfrenta alto riesgo y 31.5 % muy alto riesgo (Lamhadri et al., 2025). El impacto del aumento del nivel del mar amplifica aún más este riesgo, con la pérdida de hábitat resultando en un 43.8 % de la costa clasificada como riesgo muy alto y 39.3 % como alto riesgo.

Artículo 2: El análisis de Moran global y local detecta clusters regionales de incidencia de paperas, fortaleciendo la comprensión de interacciones socioambientales (Hu et al., 2025). La prueba estadística confirmó significancia con $Z > 1.96$ ($p < 0.05$), indicando agregación espacial de la incidencia de paperas. Los clusters alto-alto se concentraron en regiones occidentales (Qinghai, Tibet, Yunnan y Guangxi), mientras que los clusters bajo-bajo predominaron en el este de China, particularmente en la provincia de Jilin (Hu et al., 2025). El análisis reveló que el índice de Moran global fue de 0.399 ($p < 0.001$), confirmando una fuerte dependencia espacial de la transmisión. Entre todos los factores influyentes, el índice de dependencia infantil mostró la asociación más fuerte con la incidencia de paperas ($PD = 0.54$), mientras que los recursos de salud exhibieron efectos relativamente más débiles.

Artículo 3: El Moran bivariado ($I = 0.88$, $p < 0.01$) entre NDVI y precipitación confirma una alta sensibilidad climática de la vegetación y permite delinear zonas prioritarias de restauración ecológica (Yan et al., 2025). El análisis LISA identificó patrones de concentración alto-alto (H-H) en las montañas Damaqu y la región sur de Manhanshan, donde las condiciones de crecimiento vegetativo eran favorables, y bajo-bajo (L-L) en las montañas Langshan orientales, donde la vegetación era relativamente escasa, revelando heterogeneidad espacial significativa (Yan et al., 2025). El estudio demostró que la precipitación fue el factor climático dominante que influye en las variaciones del NDVI en las montañas Yinshan, con una correlación positiva de hasta 80.05 % del área total, mientras que la temperatura mostró una correlación negativa en 55.79 % de las áreas.

2. Implementación en R: Cálculo del Índice de Moran Global

2.1. Librerías Necesarias

```
# Instalacion de paquetes (ejecutar solo una vez)
install.packages("sp")           # Manejo de datos espaciales
install.packages("spdep")        # Analisis de dependencia espacial
install.packages("rgdal")        # Lectura/escritura de archivos GIS
install.packages("maptools")     # Manipulacion de mapas

# Cargar librerias
library(sp)                     # Clases y metodos para datos espaciales
library(spdep)                  # Estadisticas espaciales y autocorrelacion
library(rgdal)                  # Interfaz GDAL para formatos geoespaciales
library(maptools)               # Herramientas para objetos espaciales
```

2.2. Interpretación de las Librerías

- **sp**: Proporciona clases fundamentales para representar datos espaciales en R (puntos, líneas, polígonos). Es la base para operaciones geoespaciales.
- **spdep**: Contiene funciones para análisis de autocorrelación espacial, incluyendo el índice de Moran, Geary's C, y pruebas de hipótesis espaciales.
- **rgdal**: Interfaz con la librería GDAL (Geospatial Data Abstraction Library), permitiendo leer/escribir múltiples formatos GIS (shapefiles, GeoTIFF, etc.).
- **maptools**: Ofrece herramientas adicionales para manipular y visualizar objetos espaciales.

2.3. Creación de Polígonos Espaciales Simulados

```
# Crear 10 poligonos contiguos simulando una costa
polys_list <- vector("list", 10)

for(i in 1:10) {
  # Definir coordenadas de cada poligono rectangular
  x_coords <- c(i - 0.5, i + 0.5, i + 0.5, i - 0.5, i - 0.5)
  y_coords <- c(0.5, 0.5, 1.5, 1.5, 0.5)

  # Crear matriz de coordenadas
  coords_i <- matrix(c(x_coords, y_coords), ncol = 2)

  # Crear objeto Polygon
  poly_i <- Polygon(coords_i)

  # Crear objeto Polygons con ID unico
  polys_list[[i]] <- Polygons(list(poly_i), ID = as.character(i))
}

# Crear objeto SpatialPolygons
sp_poly <- SpatialPolygons(polys_list)

# Asignar sistema de coordenadas geograficas WGS84
proj4string(sp_poly) <- CRS("+proj=longlat+datum=WGS84")
```

2.4. Interpretación

Este código genera 10 polígonos rectangulares contiguos que simulan una franja costera lineal, similar a las configuraciones costeras analizadas en el estudio de Lamhadri et al. (2025). Cada polígono:

- Tiene dimensiones de 1 unidad de ancho \times 1 unidad de alto

- Se posiciona secuencialmente de izquierda a derecha ($i = 1$ a 10)
- Comparte bordes con sus vecinos adyacentes
- Utiliza el sistema de coordenadas WGS84 (EPSG:4326), estándar global para datos GPS

Esta configuración lineal es representativa de zonas costeras donde las unidades espaciales se extienden paralelamente a la línea de costa, como se observó en los estudios de vulnerabilidad costera (Lamhadri et al., 2025).

2.5. Asignación de Variable de Exposición

```
# Variable simulada: exposicion costera (rango 0-1)
set.seed(123) # Semilla para reproducibilidad

# Generar valores aleatorios para todos los poligonos
exposicion <- runif(10, 0, 1)

# Incrementar exposicion en poligonos 6-10 (zona sur)
exposicion[6:10] <- runif(5, 0.6, 1)

# Crear SpatialPolygonsDataFrame (union de geometria + datos)
sp_df <- SpatialPolygonsDataFrame(sp_poly,
                                  data.frame(exposicion = exposicion))

# Verificar estructura de datos
print(sp_df)
summary(sp_df$exposicion)
```

2.6. Interpretación

La variable `exposicion` representa el nivel de vulnerabilidad costera en cada polígono, siguiendo la metodología del modelo InVEST utilizado por Lamhadri et al. (2025):

- **Polígonos 1-5:** Valores uniformemente distribuidos entre 0 y 1, simulando condiciones variables de exposición.
- **Polígonos 6-10:** Valores elevados entre 0.6 y 1, representando una zona sur con mayor riesgo (similar al patrón observado en el estudio de costas de Marruecos, donde Sidi Moussa presentó mayor exposición).
- **Reproducibilidad:** `set.seed(123)` garantiza que los valores aleatorios sean idénticos en cada ejecución.

El objeto `SpatialPolygonsDataFrame` integra geometría espacial y atributos, permitiendo análisis espaciales completos similares a los realizados en estudios de vulnerabilidad costera (Lamhadri et al., 2025).

2.7. Construcción de Matriz de Pesos Espaciales

```
# Crear matriz de pesos espaciales (contiguidad queen)
w <- poly2nb(sp_df, queen = TRUE, snap = 0.01)
print(w) # Verificar lista de vecinos

# Convertir a objeto listw (lista de pesos estandarizada)
w_list <- nb2listw(w, style = "W", zero.policy = TRUE)

# Visualizar estructura de vecindad
summary(w_list)
```

2.8. Salida del Comando

```
Neighbour list object:  
Number of regions: 10  
Number of nonzero links: 18  
Percentage nonzero weights: 18  
Average number of links: 1.8
```

2.9. Interpretación de la Matriz de Pesos Espaciales

La matriz de vecindad generada mediante el criterio de **contigüidad queen** (que considera como vecinos aquellos polígonos que comparten vértices o bordes) revela la estructura espacial del conjunto de datos. El análisis identifica 10 polígonos costeros simulados con 18 conexiones espaciales entre polígonos vecinos, lo que representa un 18% de pesos no nulos, indicando una estructura espacial relativamente dispersa. El promedio de vecinos es de 1.8 por región, lo cual es consistente con una configuración lineal costera donde cada polígono comparte bordes con uno o dos vecinos adyacentes.

Los parámetros configurados en el análisis tienen implicaciones importantes para la detección de vecindades. El parámetro **queen = TRUE** incluye polígonos que comparten cualquier punto, ya sean bordes o vértices, siendo más inclusivo que el criterio **rook** que solo considera bordes compartidos. La tolerancia geométrica **snap = 0.01** permite detectar toques cercanos, evitando que errores de precisión numérica impidan identificar vecindades reales. La estandarización **style = "W"** normaliza por filas, donde cada fila de la matriz de pesos suma 1, otorgando igual importancia relativa a cada vecino. Finalmente, el parámetro **zero.policy = TRUE** permite manejar unidades sin vecinos, aunque en este caso todas las unidades tienen al menos un vecino.

2.10. Cálculo del Índice de Moran Global

```
# Calcular Moran's I global con prueba de significancia
moran_test <- moran.test(sp_df$exposicion,
                        listw = w_list,
                        randomisation = TRUE)

# Mostrar resultados
print(moran_test)

# Extraer componentes específicos
cat("\nEstadístico de Moran I:", moran_test$estimate[1], "\n")
cat("Valor esperado bajo H0:", moran_test$estimate[2], "\n")
cat("Varianza:", moran_test$estimate[3], "\n")
cat("Valor p:", moran_test$p.value, "\n")
```

2.11. Salida del Comando

```
      Moran I test under randomisation

data:  sp_df$exposicion
weights: w_list

Moran I statistic standard deviate = 0.33509, p-value = 0.3688
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
      -0.01133171      -0.11111111      0.08866634
```

2.12. Interpretación del Índice de Moran Global

Estadístico	Valor
Moran I observado	-0.0113
Expectativa bajo H_0 (aleatoriedad)	-0.1111
Desviación estándar	0.3351
Valor p (unilateral)	0.3688
Varianza	0.0887

Cuadro 1: Resultados de la prueba de Moran I bajo randomización.

El **índice de Moran I** = **-0.0113** se encuentra muy cercano a cero, sugiriendo una distribución **prácticamente aleatoria** de los valores de exposición en el espacio. Este resultado puede interpretarse de la siguiente manera:

Ausencia de autocorrelación espacial significativa: El valor $p = 0.3688$ (> 0.05) indica que no se puede rechazar la hipótesis nula de aleatoriedad espacial. No existe evidencia estadística de que las regiones vecinas presenten valores de exposición similares.

Valor ligeramente negativo: Aunque cercano a cero, el signo negativo podría sugerir una *débil* tendencia hacia la dispersión (valores disímiles entre vecinos), pero no alcanza significancia estadística.

Comparación con la expectativa: Bajo la hipótesis nula de distribución espacial aleatoria, el valor esperado de Moran I es -0.1111 (calculado como $-1/(n-1) = -1/9$). El valor observado (-0.0113) está más cerca de cero que esta expectativa, confirmando la aleatoriedad.

Limitaciones del análisis: Con solo 10 regiones y un promedio de 1.8 vecinos por unidad, el poder estadístico de la prueba es limitado. Una muestra más grande podría revelar patrones espaciales más claros, como se demostró en estudios con mayor número de unidades espaciales (Hu et al., 2025; Yan et al., 2025).

2.13. Visualización del Mapa de Exposición

```
# Crear mapa de exposicion con escala de grises
plot(sp_df,
     col = rev(gray(1 - sp_df$exposicion)),
     axes = TRUE,
     border = "black",
     main = "Mapa de Exposicion con Clustering Espacial (Poligonos Contiguos)")

# Agregar leyenda
legend("topright",
     legend = round(sp_df$exposicion, 2),
     fill = rev(gray(1 - sp_df$exposicion)),
     title = "Exposicion",
     cex = 0.8)

# Agregar etiquetas de ID en cada poligono
text(coordinates(sp_df),
     labels = 1:10,
     cex = 0.7,
     col = "red")
```

Mapa de Exposición con Clustering Espacial (Polígonos Contiguos)




Figura 1: Mapa de exposición costera con polígonos contiguos. La intensidad del color representa el nivel de exposición (valores más oscuros indican mayor exposición).

2.14. Interpretación del Mapa

El mapa de exposición muestra la distribución espacial de los valores simulados a lo largo de una franja costera lineal, siguiendo la metodología cartográfica utilizada en estudios de vulnerabilidad costera (Lamhaddri et al., 2025). Se observa un gradiente de exposición concentrado en la zona central-derecha del mapa, correspondiente a los polígonos 6 al 10, con valores que oscilan entre 0.64 y 0.98, lo que indica áreas de mayor vulnerabilidad relativa. Sin embargo, la disposición geométrica en línea de los polígonos limita la cantidad de vecinos espaciales, reduciendo la posibilidad de una autocorrelación significativa. Aunque se introdujeron valores más altos en la mitad final de la secuencia, el índice de Moran no evidencia un patrón estadísticamente consistente de agrupamiento. Además, la presencia de variaciones abruptas entre polígonos adyacentes, como

saltos de 0.29 a 0.79, refuerza la existencia de una heterogeneidad local que debilita la estructura espacial global del fenómeno simulado.

2.15. Comparación con los Artículos Analizados

Estudio	Moran I	Significancia	Interpretación
Artículo 1 (Costas Marruecos) (Lamhadri et al., 2025)	0.70	$p \leq 0.01$	Clustering espacial fuerte de exposición costera
Artículo 2 (Paperas China) (Hu et al., 2025)	0.399	$p \leq 0.001$	Clusters alto-alto (oeste) y bajo-bajo (este)
Artículo 3 (Vegetación China) (Yan et al., 2025)	0.88	$p \leq 0.01$	Fuerte asociación NDVI-precipitación
Simulación actual	-0.011	$p = 0.37$	Sin autocorrelación significativa

Cuadro 2: Comparación de índices de Moran entre estudios reales y simulación.

La diferencia entre los resultados de la simulación y los artículos científicos radica en varios factores fundamentales:

Escala espacial: Los estudios reales abarcan áreas geográficas extensas con cientos o miles de unidades espaciales, aumentando el poder estadístico. Por ejemplo, Hu et al. (2025) analizaron 31 provincias chinas, mientras que Lamhadri et al. (2025) procesaron 267 puntos costeros con resolución de 100 metros.

Procesos subyacentes: Los fenómenos naturales y epidemiológicos reales exhiben dependencia espacial genuina debido a procesos de difusión, gradientes climáticos y factores socioeconómicos (Hu et al., 2025; Yan et al., 2025), mientras que la simulación asignó valores semi-aleatorios sin modelar procesos espaciales reales.

Configuración de vecindad: Las regiones reales presentan redes de vecindad más complejas con múltiples vecinos por unidad, facilitando la propagación de patrones espaciales. El estudio de Yan et al. (2025) demostró clusters H-H y L-L bien definidos en configuraciones bidimensionales complejas.

2.16. Conclusiones del Análisis Espacial

El índice de Moran I es una herramienta robusta para detectar autocorrelación espacial, pero su interpretación debe considerar el tamaño muestral y la configuración geométrica de las unidades espaciales.

La ausencia de autocorrelación significativa en la simulación ($\text{Moran I} \approx 0$) contrasta con los patrones de clustering observados en fenómenos ambientales y epidemiológicos reales (Lamhadri et al., 2025; Hu et al., 2025; Yan et al., 2025), subrayando la importancia de procesos espaciales subyacentes.

La metodología implementada (construcción de polígonos, matriz de pesos, prueba de Moran) es replicable y aplicable a estudios de exposición costera, incidencia de enfermedades y dinámicas de vegetación.

Para obtener resultados comparables con los artículos analizados, se requeriría aumentar el número de unidades espaciales, incorporar procesos generadores de dependencia espacial realista, y utilizar datos empíricos.

La visualización cartográfica complementa la prueba estadística, permitiendo identificar patrones locales no capturados por índices globales como el Moran I.

3. Referencias Bibliográficas

Referencias

- Hu, K., Li, C., Yang, X., Xiao, D., Zhang, X., and Yu, M. (2025). Spatial stratified heterogeneity of mumps incidence in china: a geodetector-based analysis of driving factors. *Frontiers in Public Health*, 13:1637288.
- Lamhadri, S., Senechal, N., Ouallali, A., El Hafyani, M., Chahid, D., and Benhachmi, M. K. (2025). Assessing coastal exposure to sea level rise: a coupled approach of qualitative modeling and spatial autocorrelation analysis. *Natural Hazard Research*. In press.
- Yan, M., Lu, J., Ma, Y., and Ma, C. (2025). A remote sensing evidence on the marginality, fragmentation and spatiotemporal heterogeneity of vegetation evolution characteristics in the yinshan mountains, china: Based on pku gimms ndvi (1984–2022). *Ecological Indicators*, 171:113193.