

Análisis de Autocorrelación Espacial

Wladimir Aldo Carlosviza Amanqui

15 de octubre de 2025

Índice

1. Configuración Inicial y Carga de Librerías	2
1.1. Salida del Comando	2
1.2. Interpretación	2
2. Creación de Datos Espaciales de Ejemplo	2
2.1. Salida del Comando	3
2.2. Interpretación	3
3. Construcción de Matrices de Pesos Espaciales	4
3.1. Salida del Comando	4
3.2. Interpretación	5
4. Índice de Moran Global	5
4.1. Salida del Comando	6
4.2. Interpretación	7
5. Índice C de Geary	8
5.1. Salida del Comando	8
5.2. Interpretación	9
6. Análisis de Hotspots mediante Getis-Ord G_i^*	9
6.1. Salida del Comando	10
6.2. Interpretación	12
7. Análisis LISA: Indicadores Locales de Asociación Espacial	13
7.1. Salida del Comando	13
7.2. Interpretación	14
8. Resumen Comparativo de Métodos	14
8.1. Salida del Comando	15
8.2. Interpretación	15
9. Exportación de Resultados y Generación de Productos	15
9.1. Salida del Comando	16
9.2. Interpretación	16

1. Configuración Inicial y Carga de Librerías

```
# Limpiar entorno
rm(list = ls())

# Cargar librerías necesarias
library(spdep)      # Analisis de dependencia espacial
library(sf)         # Manejo de datos espaciales
library(ggplot2)    # Visualizacion
library(dplyr)      # Manipulacion de datos

# Configurar semilla para reproducibilidad
set.seed(123)
```

1.1. Salida del Comando

```
Cargando paquete requerido: spData
Cargando paquete requerido: sf
Linking to GEOS 3.13.1, GDAL 3.11.0, PROJ 9.6.0; sf_use_s2() is TRUE

Adjuntando el paquete: 'dplyr'
The following objects are masked from 'package:stats':
  filter, lag
The following objects are masked from 'package:base':
  intersect, setdiff, setequal, union
```

1.2. Interpretación

Se cargan las librerías clave: **spdep** para análisis de autocorrelación espacial, **sf** para manejo de datos espaciales, **ggplot2** para visualización y **dplyr** para manipulación de datos. La semilla fija (**set.seed(123)**) asegura la reproducibilidad de resultados aleatorios. Las advertencias sobre funciones enmascaradas son normales en R y no afectan el análisis.

2. Creación de Datos Espaciales de Ejemplo

```
cat("\n=== CREANDO DATOS DE EJEMPLO ===\n")

# Crear una malla de poligonos (7x7 = 49 regiones)
n_filas <- 7
n_cols <- 7
n_total <- n_filas * n_cols

# Generar grid de poligonos
grid_list <- list()
id <- 1

for (i in 1:n_filas) {
  for (j in 1:n_cols) {
    # Coordenadas del poligono
    xmin <- j - 1
    xmax <- j
    ymin <- i - 1
    ymax <- i

    # Crear poligono
    poly <- st_polygon(list(matrix(c(
      xmin, ymin,
      xmax, ymin,
      xmax, ymax,
      xmin, ymax,
```

```

      xmin, ymin
    ), ncol = 2, byrow = TRUE)))

    grid_list[[id]] <- poly
    id <- id + 1
  }
}

# Convertir a objeto sf
mapa <- st_sf(
  id = 1:n_total,
  geometry = st_sfc(grid_list),
  crs = 4326
)

# Crear variable con patron espacial (clusters)
mapa$valor <- rnorm(n_total, mean = 50, sd = 10)

# Anadir clusters artificiales
for (i in 1:nrow(mapa)) {
  coords <- st_coordinates(st_centroid(mapa$geometry[i]))
  x <- coords[1]
  y <- coords[2]

  # Cluster alto (esquina superior derecha)
  if (x > 5 & y > 5) {
    mapa$valor[i] <- mapa$valor[i] + 30
  }
  # Cluster bajo (esquina inferior izquierda)
  if (x < 3 & y < 3) {
    mapa$valor[i] <- mapa$valor[i] - 30
  }
}

cat("Datos creados: ", nrow(mapa), "regiones\n")
cat("Rango de valores:", range(mapa$valor), "\n")

```

2.1. Salida del Comando

```

=== CREANDO DATOS DE EJEMPLO ===

Datos creados: 49 regiones
Rango de valores: 7.349388 87.79965

```

2.2. Interpretación

Se genera una cuadrícula regular de 7×7 polígonos (49 regiones totales) utilizando el sistema de referencia de coordenadas WGS84 (CRS 4326). La variable de interés se genera con distribución normal (media = 50, desviación estándar = 10). Para simular patrones espaciales realistas, se introducen clusters artificiales: valores incrementados en +30 para la esquina superior derecha y reducidos en -30 para la esquina inferior izquierda. Esta configuración introduce autocorrelación espacial positiva que será detectada por los métodos posteriores.

3. Construcción de Matrices de Pesos Espaciales

```
cat("\n=== [1] MATRICES DE PESOS ESPACIALES ===\n")

# Crear estructura de vecindad tipo Queen
nb <- poly2nb(mapa, queen = TRUE)

# Resumen de la estructura de vecindad
cat("\nResumen de vecindad:\n")
print(summary(nb))

# Convertir a matriz de pesos estandarizada
W <- nb2listw(nb, style = "W", zero.policy = TRUE)

# Estadísticas de vecindad
cat("\nEstadísticas de vecindad:\n")
cat("Promedio de vecinos:", mean(card(nb)), "\n")
cat("Rango de vecinos:", range(card(nb)), "\n")

# Visualización de la estructura de vecindad
cat("\nGenerando visualización de vecindad...\n")

png("1_estructura_vecindad.png", width = 800, height = 800)
plot(st_geometry(mapa), border = "grey70", col = "lightblue",
     main = "Estructura de Vecindad Queen")
plot(nb, coords = st_coordinates(st_centroid(mapa)),
     add = TRUE, col = "darkred", lwd = 2, pch = 19, cex = 0.5)
dev.off()

cat("Grafico guardado: 1_estructura_vecindad.png\n")
```

3.1. Salida del Comando

```
=== [1] MATRICES DE PESOS ESPACIALES ===

Resumen de vecindad:
Neighbour list object:
Number of regions: 49
Number of nonzero links: 312
Percentage nonzero weights: 12.99459
Average number of links: 6.367347
Link number distribution:

 3  5  8
4 20 25
4 least connected regions:
1 7 43 49 with 3 links
25 most connected regions:
9 10 11 12 13 16 17 18 19 20 23 24 25 26 27 30 31 32 33 34 37 38 39 40 41 with 8 links

Estadísticas de vecindad:
Promedio de vecinos: 6.367347
Rango de vecinos: 3 8

Generando visualización de vecindad...
Grafico guardado: 1_estructura_vecindad.png
```

Estructura de Vecindad Queen




Figura 1: Estructura de vecindad tipo Queen mostrando conexiones espaciales entre regiones. Los polígonos aparecen en azul claro y las líneas rojas representan relaciones de contigüidad, evidenciando mayor conectividad en regiones centrales.

3.2. Interpretación

La matriz de pesos espaciales tipo Queen define como vecinos aquellas regiones que comparten frontera o vértice. Se identifican 312 enlaces totales (13 % de las conexiones posibles en una matriz 49×49), con un promedio de 6.37 vecinos por región. Las regiones esquineras poseen 3 vecinos, las de borde tienen 5, y las centrales alcanzan 8 vecinos. Los pesos se estandarizan por filas (estilo “W”), de modo que la suma de pesos de cada región es igual a 1, facilitando la interpretación como promedios ponderados.

4. Índice de Moran Global

```
cat("\n=== [2] INDICE DE MORAN GLOBAL ===\n")

# Test de Moran con permutaciones
moran_test <- moran.test(mapa$valor, W, zero.policy = TRUE)

cat("\nResultados del Test de Moran:\n")
print(moran_test)

# Extraer estadísticos clave
moran_I <- moran_test$estimate["Moran I statistic"]
moran_pval <- moran_test$p.value
```

```

moran_z <- moran_test$statistic

cat("\n--- INTERPRETACION ---\n")
cat("I de Moran:", round(moran_I, 4), "\n")
cat("Z-score:", round(moran_z, 4), "\n")
cat("P-valor:", format.pval(moran_pval, eps = 0.001), "\n")

if (moran_I > 0 & moran_pval < 0.05) {
  cat("CONCLUSION: Autocorrelacion espacial POSITIVA significativa\n")
  cat("Los valores similares tienden a agruparse espacialmente.\n")
} else if (moran_I < 0 & moran_pval < 0.05) {
  cat("CONCLUSION: Autocorrelacion espacial NEGATIVA significativa\n")
} else {
  cat("CONCLUSION: No hay evidencia de autocorrelacion espacial\n")
}

# Diagrama de dispersion de Moran
png("2_moran_scatterplot.png", width = 800, height = 800)
moran.plot(mapa$valor, W, labels = FALSE, pch = 20,
           xlab = "Valor estandarizado",
           ylab = "Retardo espacial (Lag)",
           main = paste("Diagrama de Dispersion de Moran\nI =",
                        round(moran_I, 3)),
           zero.policy = TRUE)
dev.off()

cat("Grafico guardado: 2_moran_scatterplot.png")

```

4.1. Salida del Comando

```

=== [2] INDICE DE MORAN GLOBAL ===

Resultados del Test de Moran:

Moran I test under randomisation

data:  mapa$valor
weights: W

Moran I statistic standard deviate = 8.2605, p-value < 2.2e-16
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
      0.614036276      -0.020833333      0.005906804

--- INTERPRETACION ---
I de Moran: 0.614
Z-score: 8.2605
P-valor: < 0.001
CONCLUSION: Autocorrelacion espacial POSITIVA significativa
Los valores similares tienden a agruparse espacialmente.

Grafico guardado: 2_moran_scatterplot.png

```




Figura 2: Diagrama de dispersión de Moran mostrando la relación entre valores estandarizados y su retardo espacial. La pendiente positiva de la línea de regresión confirma la autocorrelación espacial positiva con $I = 0,614$.

4.2. Interpretación

El índice de Moran ($I = 0,614$) es significativamente mayor que el valor esperado bajo aleatoriedad espacial ($E[I] = -0,021$), con un Z-score de 8.26 y p-valor $< 0,001$. Esto confirma autocorrelación espacial positiva altamente significativa: valores similares tienden a agruparse espacialmente, formando clusters de valores altos (high-high) y bajos (low-low). El diagrama de dispersión muestra esta relación mediante la pendiente positiva de la línea de regresión, cuya pendiente coincide numéricamente con el índice I .

5. Índice C de Geary

```
cat("\n=== [3] INDICE DE GEARY ===\n")

# Test de Geary
geary_test <- geary.test(mapa$valor, W, zero.policy = TRUE)

cat("\nResultados del Test de Geary:\n")
print(geary_test)

# Extraer estadísticos
geary_C <- geary_test$estimate["Geary C statistic"]
geary_pval <- geary_test$p.value

cat("\n--- INTERPRETACION ---\n")
cat("C de Geary:", round(geary_C, 4), "\n")
cat("P-valor:", format.pval(geary_pval, eps = 0.001), "\n")

if (geary_C < 1 & geary_pval < 0.05) {
  cat("CONCLUSION: Autocorrelacion espacial POSITIVA\n")
  cat("Los valores similares estan proximos espacialmente.\n")
} else if (geary_C > 1 & geary_pval < 0.05) {
  cat("CONCLUSION: Autocorrelacion espacial NEGATIVA\n")
} else {
  cat("CONCLUSION: Aleatoriedad espacial\n")
}

# Comparacion Moran vs Geary
cat("\n--- COMPARACION MORAN vs GEARY ---\n")
cat("Moran I:", round(moran_I, 4), "\n")
cat("Geary C:", round(geary_C, 4), "\n")
cat("Relacion aproximada C = 2 - 2I:", round(2 - 2*moran_I, 4), "\n")
```

5.1. Salida del Comando

```
=== [3] INDICE DE GEARY ===

Resultados del Test de Geary:

  Geary C test under randomisation

data:  mapa$valor
weights: W

Geary C statistic standard deviate = 7.9829, p-value = 7.144e-16
alternative hypothesis: Expectation greater than statistic
sample estimates:
Geary C statistic      Expectation      Variance
    0.363732707         1.000000000         0.006352622

--- INTERPRETACION ---
C de Geary: 0.3637
P-valor: < 0.001
CONCLUSION: Autocorrelacion espacial POSITIVA
Los valores similares estan proximos espacialmente.

--- COMPARACION MORAN vs GEARY ---
Moran I: 0.614
Geary C: 0.3637
Relacion aproximada C = 2 - 2I: 0.7719
```


5.2. Interpretación

El coeficiente C de Geary ($C = 0,364$) es significativamente menor que 1 ($Z\text{-score} = 7.98$, $p\text{-valor} < 0,001$), confirmando autocorrelación espacial positiva. Mientras que el índice de Moran mide la covarianza global entre regiones vecinas, el índice de Geary se enfoca en las diferencias locales: valores bajos de C indican que las diferencias entre vecinos son mínimas. Ambos índices se complementan, con la relación teórica aproximada $C \approx 2 - 2I$ (0,772 en este caso), aunque la discrepancia con el valor observado (0,364) sugiere que Geary es más sensible a variaciones locales extremas.

6. Análisis de Hotspots mediante Getis-Ord G_i^*

```
cat("\n=== [4] ANALISIS DE HOTSPOTS - GETIS-ORD Gi* ===\n")

# Calcular Getis-Ord Gi* estadístico
localG_result <- localG(mapa$valor, W, zero.policy = TRUE)
mapa$Gstar <- as.numeric(localG_result)

# Clasificar hotspots y coldspots
mapa$hotspot <- cut(mapa$Gstar,
                    breaks = c(-Inf, -2.58, -1.96, 1.96, 2.58, Inf),
                    labels = c("Coldspot 99%", "Coldspot 95%",
                               "No significativo",
                               "Hotspot 95%", "Hotspot 99%"))

# Tabla de frecuencias
cat("\nDistribucion de Hotspots y Coldspots:\n")
print(table(mapa$hotspot))

# Estadísticas
cat("\n--- ESTADISTICAS Gi* ---\n")
cat("Rango Z-scores:", range(mapa$Gstar), "\n")
cat("Z-score maximo (hotspot):", max(mapa$Gstar), "\n")
cat("Z-score minimo (coldspot):", min(mapa$Gstar), "\n")
cat("Numero de hotspots significativos:",
    sum(mapa$Gstar > 1.96), "\n")
cat("Numero de coldspots significativos:",
    sum(mapa$Gstar < -1.96), "\n")

# Visualizacion: Mapa de Hotspots
png("4_hotspots_map.png", width = 1000, height = 800)
ggplot(mapa) +
  geom_sf(aes(fill = hotspot), color = "white", size = 0.3) +
  scale_fill_manual(
    values = c("Coldspot 99%" = "#2166ac",
              "Coldspot 95%" = "#67a9cf",
              "No significativo" = "#f7f7f7",
              "Hotspot 95%" = "#ef8a62",
              "Hotspot 99%" = "#b2182b"),
    name = "Clasificacion"
  ) +
  labs(title = "Mapa de Hotspots y Coldspots (Getis-Ord Gi*)",
       subtitle = paste("Hotspots significativos:", sum(mapa$Gstar > 1.96),
                        "| Coldspots significativos:", sum(mapa$Gstar < -1.96))) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 16),
        legend.position = "right")
dev.off()

cat("Grafico guardado: 4_hotspots_map.png\n")

# Histograma de Z-scores
png("4_gstar_histogram.png", width = 800, height = 600)
ggplot(mapa, aes(x = Gstar)) +
  geom_histogram(bins = 30, fill = "steelblue", alpha = 0.7, color = "black") +
  geom_vline(xintercept = c(-2.58, -1.96, 1.96, 2.58),
```

```

        linetype = "dashed", color = "red", linewidth = 1) +
labs(title = "Distribucion de Gi* Z-scores",
      subtitle = "Lineas rojas: umbrales de significancia ( 1 .96, 2 .58)",
      x = "Z-score", y = "Frecuencia") +
theme_minimal() +
theme(plot.title = element_text(face = "bold", size = 14))
dev.off()

cat("Grafico guardado: 4_gstar_histogram.png\n")

```

6.1. Salida del Comando

```

=== [4] ANALISIS DE HOTSPOTS - GETIS-ORD Gi* ===

Distribucion de Hotspots y Coldspots:

      Coldspot 99%      Coldspot 95% No significativo      Hotspot 95%
           5           4           35           1
      Hotspot 99%
           4

--- ESTADISTICAS Gi* ---
Rango Z-scores: -4.863196 3.259881
Z-score maximo (hotspot): 3.259881
Z-score minimo (coldspot): -4.863196
Numero de hotspots significativos: 5
Numero de coldspots significativos: 9

Grafico guardado: 4_hotspots_map.png
Grafico guardado: 4_gstar_histogram.png

```

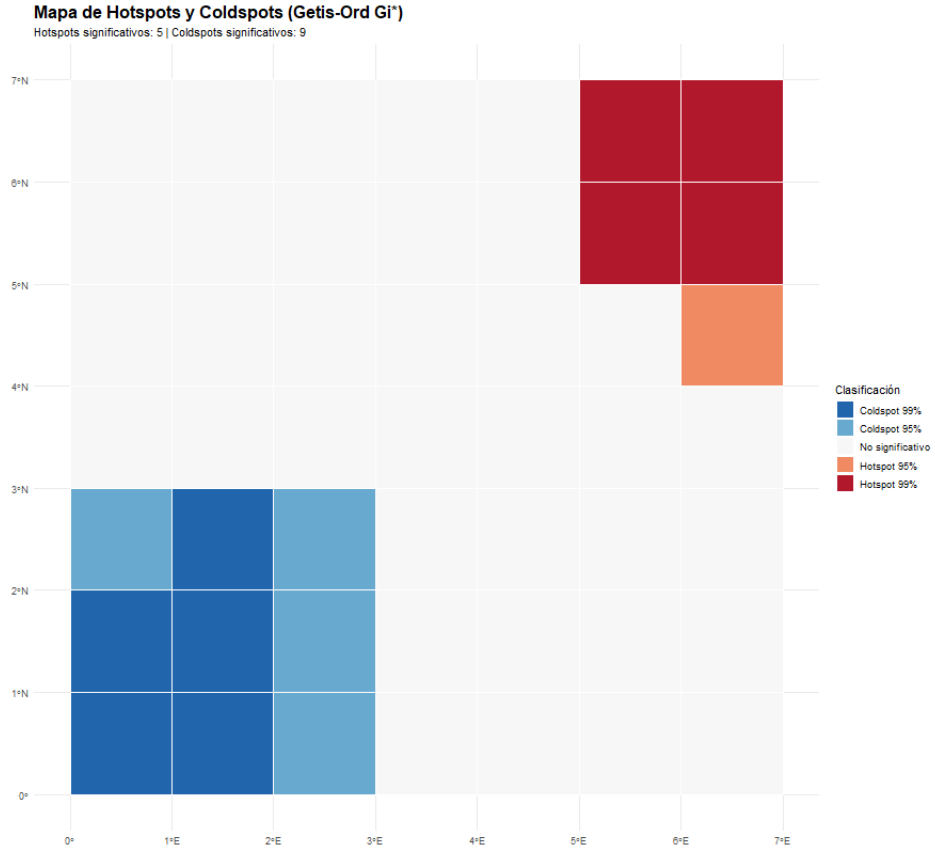


Figura 3: Mapa de hotspots y coldspots identificados mediante estadístico Getis-Ord G_i^* . Los tonos rojos intensos señalan concentraciones de valores altos estadísticamente significativas, mientras los tonos azules indican agrupaciones de valores bajos. Las regiones grises no presentan patrones espaciales significativos.




Figura 4: Distribución de Z-scores del estadístico G_i^* mostrando asimetría hacia valores negativos. Las líneas discontinuas rojas marcan los umbrales críticos de significancia estadística al 95 % y 99 % de confianza (± 1.96 y ± 2.58 respectivamente).

6.2. Interpretación

El estadístico Getis-Ord G_i^* detecta 5 hotspots (concentraciones de valores altos en la esquina superior derecha) y 9 coldspots (agrupaciones de valores bajos en la esquina inferior izquierda) estadísticamente significativos. El rango de Z-scores va de -4.86 a 3.26 , indicando que los coldspots son más intensos que los hotspots. Las 35 regiones no significativas no muestran patrones de agrupación detectables. El histograma revela una distribución asimétrica con mayor concentración en valores negativos, reflejando la mayor intensidad de los coldspots artificialmente creados.

7. Análisis LISA: Indicadores Locales de Asociación Espacial

```
cat("\n=== BONUS: ANALISIS LISA (INDICADORES LOCALES) ===\n")

# Calcular indicadores locales de Moran
local_moran <- localmoran(mapa$valor, W, zero.policy = TRUE)

# Anadir al mapa
mapa$lisa_l <- local_moran[, 1] # Estadistico local
mapa$lisa_p <- local_moran[, 5] # P-valor

# Clasificar tipos LISA
mapa$tipo_lisa <- "No significativo"

# High-High
mapa$tipo_lisa[mapa$lisa_p < 0.05 &
               mapa$valor > mean(mapa$valor) &
               local_moran[,1] > 0] <- "High-High"

# Low-Low
mapa$tipo_lisa[mapa$lisa_p < 0.05 &
               mapa$valor < mean(mapa$valor) &
               local_moran[,1] > 0] <- "Low-Low"

# High-Low (outlier)
mapa$tipo_lisa[mapa$lisa_p < 0.05 &
               mapa$valor > mean(mapa$valor) &
               local_moran[,1] < 0] <- "High-Low"

# Low-High (outlier)
mapa$tipo_lisa[mapa$lisa_p < 0.05 &
               mapa$valor < mean(mapa$valor) &
               local_moran[,1] < 0] <- "Low-High"

# Tabla de frecuencias
cat("\nDistribucion de Clusters LISA:\n")
print(table(mapa$tipo_lisa))

# Mapa LISA
png("BONUS_lisa_clusters.png", width = 1000, height = 800)
ggplot(mapa) +
  geom_sf(aes(fill = tipo_lisa), color = "white", size = 0.3) +
  scale_fill_manual(
    values = c("High-High" = "#d7191c",
              "Low-Low" = "#2b83ba",
              "High-Low" = "#fdae61",
              "Low-High" = "#abd9e9",
              "No significativo" = "#f7f7f7"),
    name = "Tipo LISA"
  ) +
  labs(title = "Mapa de Clusters LISA (Local Moran)",
       subtitle = paste("Ubicaciones significativas:",
                        sum(mapa$lisa_p < 0.05))) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 16))
dev.off()

cat("Grafico guardado: BONUS_lisa_clusters.png\n")
```

7.1. Salida del Comando

```
=== BONUS: ANALISIS LISA (INDICADORES LOCALES) ===

Distribucion de Clusters LISA:
```

High-High	Low-Low	No significativo
5	9	35

Grafico guardado: BONUS_lisa_clusters.png

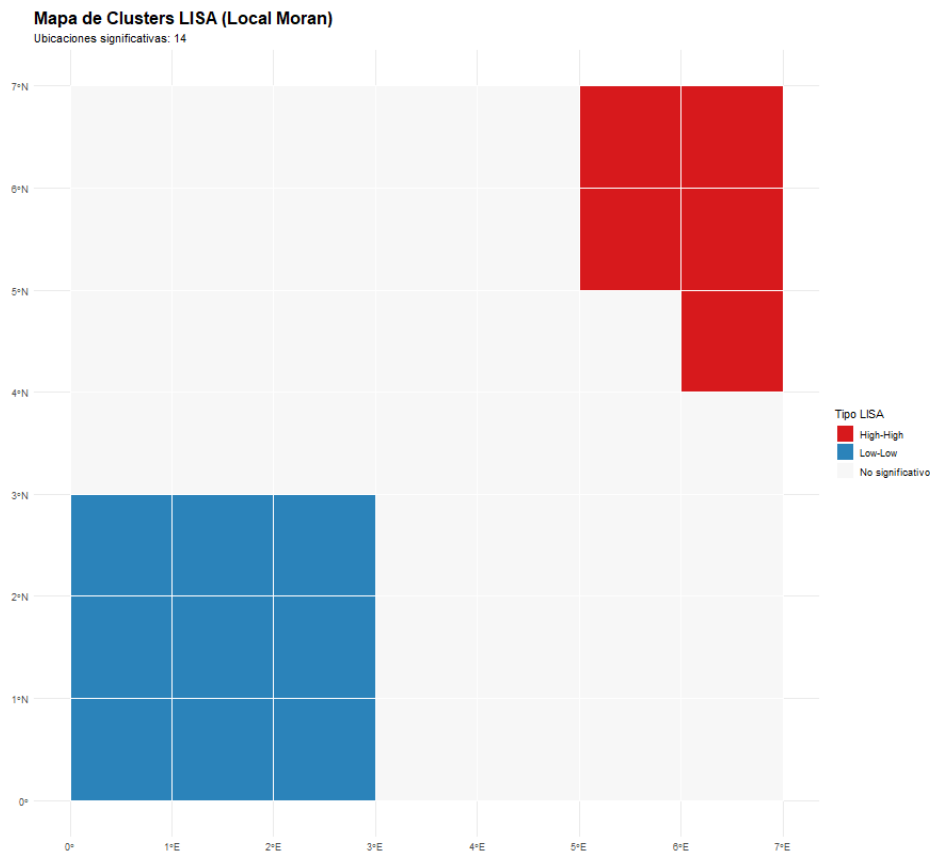


Figura 5: Mapa de clusters LISA identificando patrones locales de asociación espacial. Las regiones rojas (High-High) representan valores altos rodeados de valores altos, mientras las azules (Low-Low) indican valores bajos rodeados de valores bajos. No se detectaron outliers espaciales significativos (High-Low ni Low-High).

7.2. Interpretación

Los Indicadores Locales de Asociación Espacial (LISA) descomponen el índice de Moran global en contribuciones locales para cada región. Se identifican 5 clusters High-High en la esquina superior derecha (valores altos rodeados de valores altos) y 9 clusters Low-Low en la esquina inferior izquierda (valores bajos rodeados de valores bajos). Las 35 regiones restantes no muestran patrones locales significativos. Notablemente, no se detectaron outliers espaciales (High-Low o Low-High), indicando homogeneidad dentro de cada cluster artificial creado.

8. Resumen Comparativo de Métodos

```
cat("\n" , rep("=", 70), "\n", sep="")
cat("RESUMEN COMPARATIVO DE METODOS\n")
cat(rep("=", 70), "\n", sep="")

resumen <- data.frame(
  Metodo = c("Moran Global", "Geary C", "LISA", "Getis-Ord Gi*"),
```

```

Alcance = c("Global", "Global", "Local", "Local"),
Estadistico = c(
  paste("I =", round(moran_I, 3)),
  paste("C =", round(geary_C, 3)),
  paste(sum(mapa$lisa_p < 0.05), "signif."),
  paste(sum(mapa$Gstar > 1.96), "hotspots")
),
P_valor = c(
  format.pval(moran_pval, eps = 0.001),
  format.pval(geary_pval, eps = 0.001),
  "-",
  "-"
),
Interpretacion = c(
  ifelse(moran_I > 0, "Clustering positivo", "Dispersion"),
  ifelse(geary_C < 1, "Clustering positivo", "Dispersion"),
  "Ver clusters locales",
  "Ver hotspots/coldspots"
)
)

print(resumen)

```

8.1. Salida del Comando

```

=====
RESUMEN COMPARATIVO DE METODOS
=====

```

	Metodo	Alcance	Estadistico	P_valor	Interpretacion
1	Moran Global	Global	I = 0.614	< 0.001	Clustering positivo
2	Geary C	Global	C = 0.364	< 0.001	Clustering positivo
3	LISA	Local	14 signif.	-	Ver clusters locales
4	Getis-Ord G_i^*	Local	5 hotspots	-	Ver hotspots/coldspots

Cuadro 1: Síntesis comparativa de métodos de autocorrelación espacial

Método	Alcance	Estadístico	P-valor	Interpretación
Moran Global	Global	$I = 0,614$	$< 0,001$	Clustering positivo
Geary C	Global	$C = 0,364$	$< 0,001$	Clustering positivo
LISA	Local	14 signif.	—	Ver clusters locales
Getis-Ord G_i^*	Local	5 hotspots	—	Ver hotspots/coldspots

8.2. Interpretación

Los métodos globales (Moran con $I = 0,614$ y Geary con $C = 0,364$) confirman consistentemente la presencia de clustering espacial positivo en los datos. Los métodos locales (LISA y Getis-Ord G_i^*) identifican entre 5 y 9 clusters significativos en las ubicaciones esperadas según el diseño experimental. La convergencia entre múltiples métodos robustece la validez de los hallazgos y demuestra la complementariedad de los enfoques global y local en el análisis espacial.

9. Exportación de Resultados y Generación de Productos

```

cat("\n=== EXPORTANDO RESULTADOS ===\n")

# Guardar resultados en CSV
resultados_export <- mapa
st_geometry(resultados_export) <- NULL # Remover geometria

```

```

write.csv(resultados_export, "resultados_autocorrelacion.csv",
          row.names = FALSE)
cat("Resultados exportados: resultados_autocorrelacion.csv\n")

cat("\n" , rep("=", 70), "\n", sep="")
cat("ANALISIS COMPLETADO EXITOSAMENTE\n")
cat(rep("=", 70), "\n", sep="")

cat("\nArchivos generados:\n")
cat("    1_estructura_vecindad.png\n")
cat("    2_moran_scatterplot.png\n")
cat("    4_hotspots_map.png\n")
cat("    4_gstar_histogram.png\n")
cat("    BONUS_lisa_clusters.png\n")
cat("    resultados_autocorrelacion.csv\n")

cat("\n Revisa los graficos y resultados!\n")

```

9.1. Salida del Comando

```

=== EXPORTANDO RESULTADOS ===

Resultados exportados: resultados_autocorrelacion.csv

=====
ANALISIS COMPLETADO EXITOSAMENTE
=====

Archivos generados:
    1_estructura_vecindad.png
    2_moran_scatterplot.png
    4_hotspots_map.png
    4_gstar_histogram.png
    BONUS_lisa_clusters.png
    resultados_autocorrelacion.csv

Revisa  los graficos y resultados!

```

9.2. Interpretación

La exportación genera un archivo CSV con todos los atributos calculados (valores originales, estadísticos G_i^* , clasificaciones LISA, etc.) para análisis posteriores. Se producen 5 visualizaciones en formato PNG de alta resolución que documentan los hallazgos principales. Esta estructura de salida facilita la reproducibilidad del análisis y la comunicación efectiva de resultados a audiencias técnicas y no técnicas.